

ECOSSISTEMA DE INTELIGÊNCIA COM DATA ANALYTICS.

Desafio e Impacto Real na Associação Passos Mágicos.

**Modelo preditivo + aplicação (Streamlit) + visão analítica
(dashboard) + IA para geração de insights.**

Equipe Técnica:

Alfonso J. T. Rodriguez – RM 361699

Gabrielle Silva Santos – RM 361901

Isac João Kahan de Barros – RM 364894

Luana Tavares Faiotto – RM 362722

Data: 20-03-2026

Sumário:

Introdução.....	03
Objetivo.....	04
Base de Dados, Tratamento e Normalização.....	05
Dashboard.....	06
Questionamento Analítico.....	08
1. Adequação do nível (IAN)	
2. Desempenho acadêmico (IDA)	
3. Engajamento nas atividades (IEG)	
4. Autoavaliação (IAA)	
5. Aspectos psicossociais (IPS)	
6. Aspectos psicopedagógicos (IPP)	
7. Ponto de virada (IPV)	
8. Multidimensionalidade dos indicadores	
9. Previsão de risco com Machine Learning	
10. Efetividade do programa	
11. Insights e criatividade	
Conclusão.....	13
Recomendações.....	14
Links Úteis.....	15

INTRODUÇÃO:

Este trabalho apresenta uma plataforma analítica e preditiva desenvolvida para a **Associação Passos Mágicos**, desenhada para converter dados brutos de performance estudantil em inteligência acionável. O objetivo central é otimizar as operações da instituição e direcionar o suporte pedagógico com base em evidências estatísticas.

A solução processa o histórico consolidado e normalizado dos alunos, aplicando técnicas de estatística descritiva e algoritmos de *Machine Learning* (como *Random Forest Classifier* e Regressão Linear *OLS*) para mapear a interação entre indicadores acadêmicos, de engajamento, autoavaliação, psicossociais e psicopedagógicos.

Através da avaliação de 11 eixos analíticos, o sistema entrega:

- Diagnóstico Multidimensional: Análise de correlações entre os índices (IDA, IEG, IPS, IAA, IPP) e seu impacto direto na nota global (INDE) e na probabilidade de atingir o Ponto de Virada (IPV).
- Modelagem Preditiva e Explicabilidade: Identificação precoce do risco de defasagem estudantil utilizando modelos integrados à biblioteca *SHAP* para justificar a contribuição de cada variável no perfil do aluno.
- Avaliação de Efetividade: Cálculo do Índice de Valor Adicionado (IVA) para mensuração empírica do impacto real do programa ao longo das fases educacionais.

A ferramenta atua como um instrumento de apoio à decisão estratégica, permitindo a formulação de intervenções assertivas e planos de metas individualizados.

OBJETIVO:

De forma específica, o sistema visa:

1. Diagnosticar Dores de Negócio:

Responder a questões estratégicas mapeando a relação e o impacto de múltiplos indicadores (desempenho acadêmico, engajamento, autoavaliação, aspectos psicossociais e psicopedagógicos) na nota global (INDE) e na defasagem dos alunos.

2. Antecipar Riscos (Modelagem Preditiva):

Desenvolver um modelo preditivo para calcular a probabilidade de um aluno entrar em risco de defasagem, permitindo intervenções pedagógicas preventivas.

3. Entregar Ferramenta Gerencial e Analítica (IA):

Disponibilizar os resultados estatísticos e o modelo preditivo em uma aplicação web interativa construída no Streamlit.

O grande diferencial tecnológico desta solução é a integração com Inteligência Artificial Generativa, que atua como uma camada consultiva avançada para a instituição.

Em vez de apenas exibir painéis de dados, o sistema utiliza a IA para interpretar o cruzamento complexo de indicadores e traduzi-los em *insights* acionáveis em tempo real, como diagnosticar as raízes da volatilidade acadêmica em fases específicas e prescrever planos de intervenção pedagógica e socioemocional direcionados. Dessa forma, o *dashboard* consolida-se como um instrumento gerencial indispensável, que não apenas aponta o risco, mas orienta o educador na solução, evoluindo sua precisão a cada novo ciclo letivo através da retroalimentação dos modelos de *Machine Learning*.

BASE DE DADOS, TRATAMENTO E NORMALIZAÇÃO:

https://github.com/LuFaiotto/tech-challenge/blob/main/Fase_5/PEDE_Completo_Normalizado.xlsx

A arquitetura de dados do projeto exigiu a transição de um banco de dados relacional bruto (PEDE_database.db) para um *dataset* analítico estruturado e consolidado (PEDE_Completo_Normalizado.xlsx). Este processo de engenharia e preparação de dados foi fundamental para garantir a integridade das análises estatísticas e a precisão do modelo preditivo.

O *pipeline* de tratamento seguiu as seguintes etapas técnicas:

Consolidação Histórica: Integração dos registros longitudinais dos alunos referentes aos ciclos de 2022, 2023 e 2024 em uma estrutura única (DataFrame), permitindo a análise de evolução ao longo do tempo.

Limpeza e Conversão de Tipos: Auditoria rigorosa das colunas numéricas essenciais (IAA, IDA, IEG, IPS, IPV, IPP, IAN, INDE). Isso incluiu a padronização de formatação (substituição de vírgulas por pontos) e a conversão de *strings* para os tipos de dados numéricos adequados (float/int), eliminando ruídos que causariam falhas nos cálculos.

Tratamento de Dados Ausentes: Identificação e endereçamento de valores nulos (NaN) ou inconsistentes para evitar enviesamento nas distribuições estatísticas.

Normalização e Padronização: Ajuste das escalas dos indicadores. Esta etapa é um pré-requisito matemático crítico para garantir que os algoritmos de *Machine Learning* (como o *Random Forest* e a Regressão Linear) interpretem todas as variáveis com o mesmo peso relativo, evitando que indicadores com escalas numericamente maiores dominem o modelo preditivo.

Este fluxo transformou dados brutos em um ativo de alta confiabilidade, preparado para alimentar tanto o *dashboard* no Streamlit quanto o treinamento dos modelos preditivos.

DASHBOARD:

<https://tech-challenge-fase5.streamlit.app/>

Ferramenta Analítica e Preditiva.

O *dashboard* desenvolvido consolida-se como uma plataforma robusta de inteligência educacional, transcendendo a simples visualização de dados para atuar como um sistema de suporte à decisão pedagógica e estratégica.

Avaliando suas funcionalidades e a profundidade das análises implementadas, a ferramenta destaca-se em três pilares fundamentais:

- 1) Diagnóstico Multidimensional e Estatístico A plataforma aplica rigor estatístico (Testes T, Correlações de Pearson e Regressão OLS) para mapear o ecossistema do aluno.

Ela prova, com dados, que o desempenho acadêmico (IDA) não é um fator isolado. O sistema consegue quantificar como o engajamento (IEG), a percepção do próprio aluno (IAA), os aspectos psicossociais (IPS) e psicopedagógicos (IPP) interagem entre si, permitindo à instituição identificar perfis comportamentais (como alunos que superestimam suas notas ou que possuem alta volatilidade acadêmica).

- 2) Capacidade Preditiva e Prescritiva (Machine Learning + SHAP) O grande diferencial técnico do *dashboard* é a sua transição do formato "analítico" (olhar para o passado) para o "preditivo" (antecipar o futuro):

Ponto de Virada: Possui um modelo de alta precisão (AUC de 0.874) acoplado a um simulador interativo, permitindo que educadores testem cenários reais para descobrir o que falta para um aluno atingir seu potencial máximo.

Gestão de Risco: Implementa um modelo preditivo para evasão/defasagem suportado pela tecnologia SHAP. Isso não apenas gera uma "Fila de Prioridade" de alunos em risco, mas explica matematicamente *o porquê* cada aluno está em risco, direcionando a intervenção exata.

- 3) Mensuração de Efetividade e Visão de Negócio A ferramenta atende à diretoria e possíveis investidores ao criar métricas de impacto real, como o Índice de Valor Adicionado (IVA) geral e por fase.

Além disso, introduz análises cruzadas (como o desempenho por tipo de escola pública vs. privada) e mineração de texto nos destaques dos alunos, fornecendo inteligência para alocação de recursos e prestação de contas.

O Dashboard como ferramenta de trabalho é maduro e altamente funcional. A integração da estatística clássica, algoritmos de *Machine Learning* e *insights* gerados por Inteligência Artificial converte um volume denso de métricas em planos de ação individualizados.

É um instrumento desenhado não apenas para medir o cenário atual da Passos Mágicos, mas para atuar ativamente na redução da defasagem escolar.

QUESTIONAMENTOS ANALÍTICOS:


Nota: Todos os questionamentos analíticos estão mais bem explanados no Dashboard do Streamlit (<https://tech-challenge-fase5.streamlit.app/>) e com Insights gerados por IA.

1) Adequação do nível (IAN).

Pergunta 1 - Adequação do nível (IAN)

Qual é o perfil geral de defasagem dos alunos (IAN) e como ele evolui ao longo do ano?

Distribuição do INDE 2024




Observa-se que a média do INDE é 7,4, com desvio padrão de 1,01, indicando que os dados estão relativamente concentrados próximos à média. Isso demonstra que o desempenho geral dos alunos é estável, sem variações extremas muito acentuadas. A concentração dos valores em torno da faixa 7–8 indica que a maioria dos alunos apresenta desempenho considerado bom, com pequena dispersão entre os resultados.

2) Desempenho acadêmico (IDA).

Pergunta 2: Desempenho acadêmico (IDA)

O desempenho acadêmico médio (IDA) está melhorando, estagnado ou caindo ao longo das fases e anos?

Evolução Média do INDE




Observa-se tendência de crescimento no desempenho médio ao longo do tempo, indicando melhora progressiva dos resultados acadêmicos. Esse comportamento sugere que as estratégias educacionais aplicadas podem estar contribuindo positivamente para o avanço dos indicadores. A evolução consistente reforça um cenário de melhoria gradual no desempenho institucional.

3) Engajamento nas atividades (IEG)

Engajamento nas atividades (IEG)

O grau de engajamento dos alunos (IEG) tem relação direta com seus indicadores de desempenho (IDA) e do ponto de virada (IPV)?



Observa-se que as fases possuem desempenho relativamente equilibrado, com pequenas variações entre elas. Não há discrepâncias extremas, o que indica homogeneidade no desempenho entre os grupos.

Algumas fases apresentam médias ligeiramente superiores, podendo indicar melhor adaptação ao conteúdo ou maturidade acadêmica maior. De forma geral, o padrão é estável entre as fases.

4) Autoavaliação (IAA)

Pergunta 4: Autoavaliação (IAA)

As percepções dos alunos sobre si mesmos (IAA) são coerentes com seu desempenho real (IDA) e engajamento (IEG)?

Nesta seção, exploramos a coerência entre a **Autoavaliação (IAA)** dos alunos e seus resultados em **Desempenho Real (IDA)** e **Engajamento (IEG)**. Uma percepção alinhada com a realidade é crucial para o desenvolvimento do aluno.

Análise de Correlação

- **Correlação IAA x IDA:** 0.125, $p = 0.000$
- **Correlação IAA x IEG:** 0.122, $p = 0.000$

Valores perto de 1 indicam forte coerência positiva; perto de 0 indicam pouca relação. $p < 0.05$ sugere que a correlação não é devido ao acaso.

As correlações de Pearson nos ajudam a quantificar a força e a direção da relação entre a autoavaliação do aluno e seu desempenho e engajamento. Uma correlação positiva indica que, à medida que um aumenta, o outro também tende a aumentar. O valor-p nos informa sobre a significância estatística dessa relação.

5) Aspectos psicossociais (IPS)

Pergunta 5: Aspectos Psicossociais (IPS)

Há padrões psicossociais (IPS) que antecedem quedas de desempenho acadêmico ou de engajamento?

Nesta seção, investigamos se os **Aspectos Psicossociais (IPS)** dos alunos podem estar relacionados com **quedas no Índice de Desenvolvimento do Aluno (INDE)**. Entender essa relação é fundamental para intervenções proativas que apoiem não apenas o desempenho acadêmico, mas também o bem-estar geral do estudante.

Correlação (IPS vs variações no INDE):

	IPS
IPS	1
delta_INDE_22_23	0.1686
delta_INDE_23_24	0.1564

Os coeficientes de correlação mostram a força e a direção da relação linear entre o IPS e as variações do INDE. Um valor positivo indica que, conforme o IPS aumenta, a variação do INDE também tende a aumentar (ou seja, menos quedas ou mais ganhos). Um valor negativo sugere o oposto.

Análise para a Queda 22_23:

IPS médio (queda 22_23 vs. sem queda):

queda_22_23	count	mean	std
☐	2505	6.4426	1.6356
☒	525	5.5745	2.0697

6) Aspectos psicopedagógicos (IPP)

Pergunta 6: Aspectos Psicopedagógicos (IPP)

As avaliações psicopedagógicas (IPP) confirmam ou contradizem a defasagem identificada pelo IAN?

Nesta seção, investigamos se os **Aspectos Psicossociais (IPS)** dos alunos podem estar relacionados com **quedas no Índice de Desenvolvimento do Aluno (INDE)**. Entender essa relação é fundamental para intervenções proativas que apoiem não apenas o desempenho acadêmico, mas também o bem-estar geral do estudante.

Análise de Correlação

- Correlação de Pearson entre IPP e IAN: 0.165
- Valor-P: 0.000

O coeficiente de correlação de Pearson indica a força e a direção da relação linear entre o IPP e o IAN. Um valor próximo de 1 ou -1 sugere uma forte relação, enquanto um valor próximo de 0 indica uma relação fraca. O valor-P ajuda a determinar a significância estatística dessa correlação.

- Mediana do IAN: 5.00

7) Ponto de virada (IPV)


Pergunta 7: Ponto de Virada

Quais comportamentos - acadêmicos, emocionais ou de engajamento - mais influenciam o IPV ao longo do tempo?

Desempenho do Modelo Preditivo

AUC do Modelo (Ponto de Virada)

0.874



O modelo preditivo desenvolvido para identificar o “Ponto de Virada” apresentou AUC de 0.874, o que indica excelente capacidade de discriminação.

8) Multidimensionalidade dos indicadores.

Pergunta 8: Multidimensionalidade dos Indicadores

Quais combinações de indicadores (IDA + IEG + IPS + IPP) elevam mais a nota global do aluno (INDE)?

Informações do DataFrame para Regressão

5 primeiras linhas do DataFrame limpo para regressão:

	INDE 2023	IDA	IEG	IPS	IPP
0	6.27	4	4.1	5.6	7.28
1	7.65	6.8	5.2	6.3	8.07
2	6.55	5.6	7.9	5.6	7.44
3	6.57	5	4.5	5.6	6.82
4	7.28	5.2	8.6	5.6	7.47

Sumário do Modelo de Regressão OLS:

	Variável	Coefficiente	P-valor
0	Intercept	3.604	0.000
1	Q("IDA")	0.149	0.000
2	Q("IEG")	-0.035	0.000
3	Q("IPS")	0.090	0.000
4	Q("IPP")	0.347	0.000

9) Previsão de risco com Machine Learning

Pergunta 9: Previsão de risco com Machine Learning

Quais padrões nos indicadores permitem identificar alunos em risco antes de queda no desempenho ou aumento da defasagem? Construa um modelo preditivo que mostre uma probabilidade do aluno ou aluna entrar em risco de defasagem.

Desempenho do Modelo de Risco

AUC do Modelo de Risco

0.657

O modelo de previsão de risco acadêmico apresentou AUC de 0.657

Esse valor indica capacidade preditiva moderada. O modelo consegue identificar tendências de risco, porém com menor precisão quando comparado ao modelo de ponto de virada.

Isso sugere que a variável 'defasagem' pode depender de fatores adicionais que não estão totalmente capturados pelos indicadores analisados.

Ainda assim, o modelo é útil como ferramenta de apoio para identificação preventiva de alunos com maior probabilidade de risco.

Explicabilidade do Modelo (SHAP)

O SHAP (SHapley Additive exPlanations) ajuda a entender como cada característica individual influencia a previsão do modelo para um aluno específico.


10) Efetividade do programa

Estudantil

Pergunta 10: Efetividade do programa

Os indicadores mostram melhora consistente ao longo do ciclo nas diferentes fases (Quartzo, Ágata, Ametista e Topázio), confirmando o impacto real do programa?

Evolução do INDE ao Longo do Tempo por Fase



Observa-se que a maioria das fases apresenta crescimento ao longo do tempo, indicando evolução positiva do desempenho acadêmico.

11) Insights e criatividade

Análise de Dados de Performance Estudantil

Pergunta 11: Insights Adicionais e Criatividade

Utilizando cruzamentos de dados não solicitados nas perguntas anteriores para gerar sugestões práticas que melhorem a operação da instituição.

Análise do INDE Consolidado por Tipo de Escola

5 primeiras linhas com 'INDE 2022', 'INDE 2023', 'INDE 2024' e 'INDE_Consolidado':

	INDE 2022	INDE 2023	INDE 2024	INDE_Consolidado
0	5.78	6.27	None	6.025
1	7.06	7.65	None	7.355
2	6.59	6.55	None	6.57
3	5.95	6.57	None	6.26
4	7.43	7.28	None	7.355

O INDE Consolidado é a média dos índices de desempenho dos anos 2022, 2023 e 2024. Esta consolidação oferece uma visão mais estável e abrangente do desempenho geral do aluno ao longo do tempo.

CONCLUSÃO:

A solução analítica desenvolvida para a Associação Passos Mágicos consolida a transição de um modelo de gestão reativo para uma atuação educacional preditiva e baseada em evidências.

Ao processar e cruzar rigorosamente indicadores multidimensionais (IDA, IEG, IPS, IAA e IPP), o projeto não apenas diagnosticou o cenário histórico, mas quantificou o impacto direto do engajamento e do bem-estar psicossocial no desempenho acadêmico dos alunos.

O grande marco técnico desta entrega reside na engenharia de dados aliada aos modelos de *Machine Learning*. Com um algoritmo de alta precisão (AUC 0.874)

para prever a probabilidade do "Ponto de Virada" e um sistema de alerta para o risco de defasagem integrado à tecnologia SHAP, a ferramenta abre a "caixa preta" das previsões estatísticas.

Isso fornece à equipe pedagógica direcionamentos matematicamente embasados sobre quais variáveis específicas devem ser trabalhadas para cada aluno, operando em conjunto com as recomendações geradas via Inteligência Artificial.

Por fim, a modelagem do Índice de Valor Adicionado (IVA) entrega à diretoria uma métrica empírica e irrefutável da efetividade do programa ao longo das fases de ensino.

O *dashboard* interativo gerado neste projeto atua, portanto, como um verdadeiro motor de tomada de decisão: otimiza a alocação de esforços educacionais, gera transparência para atrair novos investidores e garante intervenções cirúrgicas para que a educação cumpra seu papel transformador com máxima eficiência.

RECOMENDAÇÕES:

Para maximizar a eficiência educacional e evoluir a maturidade dos dados nos próximos ciclos, recomenda-se tecnicamente:

1. Aumento da Granularidade na Coleta de Dados:

A análise atual baseia-se em ciclos anuais. A transição para uma coleta contínua (bimestral ou trimestral) de métricas de engajamento (IEG) e desempenho (IDA) permitirá que o modelo preditivo atue em tempo real, reduzindo o Índice de Volatilidade de Aprendizagem (IVA) antes do fechamento do ano letivo.

2. Enriquecimento da Base de Dados (Feature Engineering):

Expandir o banco de dados cruzando os indicadores internos com bases públicas de dados demográficos e de infraestrutura escolar (ex: Censo Escolar/INEP e IBGE da região do aluno). Isso aumentará a precisão do modelo ao avaliar os Aspectos Psicossociais (IPS).

3. Evolução para Modelagem de Séries Temporais:

Substituir algoritmos de classificação estáticos por modelos longitudinais (como Redes Neurais Recorrentes - RNN/LSTM). Isso permitirá prever não apenas o risco pontual, mas a trajetória de desempenho do aluno ao longo de todas as fases (da Quartzo à Topázio).

4. Sistema de Retroalimentação (Feedback Loop) das Intervenções:

Transformar o *dashboard* em uma ferramenta de mão dupla. O sistema deve permitir que os educadores registrem se o "Plano de Metas Individualizado" sugerido pela IA foi aplicado e qual foi o resultado empírico.

Esses dados de sucesso/falha da intervenção devem ser usados para retreinar o modelo, otimizando a assertividade das recomendações ao longo do tempo.

LINKS ÚTEIS:

BASE DE DADOS:

NORMALIZAÇÃO DOS DADOS EM PYTHON:

https://github.com/LuFaiotto/tech-challenge/blob/main/Fase_5/datathon_correto.py

SQLite (Bronze).

https://github.com/LuFaiotto/tech-challenge/blob/main/Fase_5/PEDE_database.db

Excel (ouro).

https://github.com/LuFaiotto/tech-challenge/blob/main/Fase_5/PEDE_Completo_Normalizado.xlsx

NOTEBOOK DA APLICAÇÃO EM PYTHON:

https://github.com/LuFaiotto/tech-challenge/blob/main/Fase_5/app.py

DASHBOARD – QUESTIONAMENTO ANALÍTICOS (Streamlit):

<https://tech-challenge-fase5.streamlit.app/>

VÍDEO (YouTube):

<https://youtu.be/sDn-JlxPqg>